深度学习基础

第 1 讲 — 深度学习导论

孟翰

人工智能学院
中国石油大学（北京）

2026 年春季学期

本讲内容

1. 课程介绍与概述
2. 人工智能、机器学习与深度学习
3. 深度学习发展历史
4. 深度学习典型应用
5. 深度学习为何有效
6. 深度学习的局限与挑战
7. 本讲小结与下讲预告

孟翰

- 中国石油大学（北京）人工智能学院
- 研究方向：可解释人工智能、时间序列分析、智能石油工程
- 邮箱：hmeng@cup.edu.cn

课程信息

- 课程名称：深度学习基础
- 授课时间：1-8 周，周三 5-6，周五 3-4
- 授课地点：三教 313

第 1–3 周：基础理论（6 讲）

- 第 1 讲 **深度学习导论**——AI/ML/DL 的关系；发展历程；典型应用
- 第 2 讲 **数学基础**——线性代数、微积分、计算图与自动微分、概率论
- 第 3 讲 **机器学习基础**——监督/无监督学习；线性回归；梯度下降；模型评估
- 第 4 讲 **从感知机到神经网络**——Softmax 与交叉熵；感知机与 XOR；多层网络
- 第 5 讲 **前馈神经网络**——激活函数；MLP 与前向传播；反向传播；参数初始化
- 第 6 讲 **训练技巧与正则化**——过拟合；权重衰减；Dropout；学习率调度

第 4 周：上机实验

- 实验一 PyTorch 基础与线性模型——张量操作、自动求导、Softmax 分类
- 实验二 多层感知机与正则化——MLP 搭建、Dropout 对比、超参数调优

第 5–7 周：进阶模型（6 讲）

- 第 7 讲 **卷积神经网络基础**——卷积运算、填充与步幅、池化层、LeNet
- 第 8 讲 **经典 CNN 架构**——AlexNet、VGG、GoogLeNet、BatchNorm、ResNet
- 第 9 讲 **循环神经网络**——序列建模；RNN 与隐状态；BPTT；GRU 门控机制
- 第 10 讲 **优化算法**——鞍点问题；SGD 变体；AdaGrad/RMSprop；Adam
- 第 11 讲 **注意力机制与 Transformer**——编码器-解码器；自注意力；多头注意力
- 第 12 讲 **Transformer 深入与总结**——位置编码；BERT/GPT/ViT；知识脉络回顾

第 8 周：上机实验

- 实验三 CNN 图像分类——ResNet 搭建、CIFAR-10 分类、迁移学习
- 实验四 序列建模综合实验——GRU 语言模型、注意力可视化、Transformer 对比

平时出勤 10% → 上机实验 40% → 期末考试 50%

平时出勤

- 课堂考勤
- 课堂参与

上机实验

- 4 次实验报告
- 每次占 10%
- 代码 + 分析 + 结果

期末考试

- 闭卷考试
- 概念 + 公式 + 分析
- 综合应用

1. **理解核心概念**：掌握深度学习的基本原理与数学基础
2. **掌握主流模型**：CNN、RNN、Transformer 等经典架构
3. **学会训练模型**：损失函数、优化器、正则化等训练技术
4. **动手实践**：使用 PyTorch 实现和训练神经网络
5. **了解前沿**：大模型、生成式 AI 等最新发展方向

学习建议

理论与实践并重——每学一个概念，动手写代码验证；每次课后，及时复习并完成练习。

定义

人工智能（Artificial Intelligence）：使机器能够模拟、延伸和扩展人类智能行为的理论、方法与技术的总称。

AI 的主要能力

- 感知：视觉、听觉、触觉
- 认知：理解、推理、规划
- 决策：判断、选择、行动
- 学习：从经验中改进
- 交互：自然语言对话

AI 的分类

- **弱人工智能**：专注特定任务（当前主流）
- **强人工智能**：具备通用智能（研究目标）
- **超人工智能**：超越人类智能（理论假设）

定义

机器学习（Machine Learning）：从数据中自动学习模式和规律，而无需针对每个任务进行显式编程的方法。

Tom Mitchell (1997) 的经典定义

一个计算机程序被称为能从经验 E 中学习，关于某类任务 T 和性能度量 P，如果它在 T 上的性能（由 P 衡量）随着经验 E 的积累而提高。

机器学习的三要素

- **数据**：学习的原材料
- **模型**：从数据到预测的映射
- **算法**：优化模型参数的方法

定义

深度学习（Deep Learning）：使用包含多个处理层（深层神经网络）的计算模型，自动从数据中学习多层次的抽象表示。

核心特点

- 多层非线性变换
- 自动特征提取
- 端到端学习
- 数据驱动

层次化特征表示

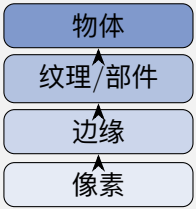

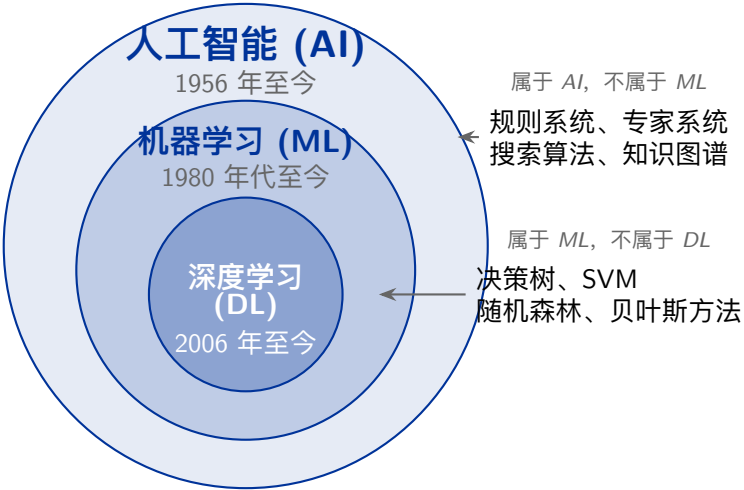
人工智能 (AI)
1956 年至今
机器学习 (ML)
1980 年代至今
深度学习 (DL)
2006 年至今
属于 AI，不属于 ML
规则系统、专家系统
搜索算法、知识图谱
属于 ML，不属于 DL
决策树、SVM
随机森林、贝叶斯方法

传统编程

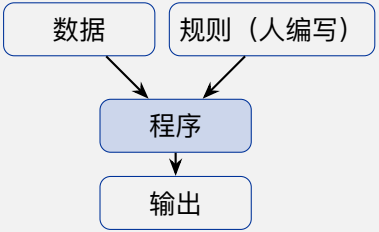

机器学习

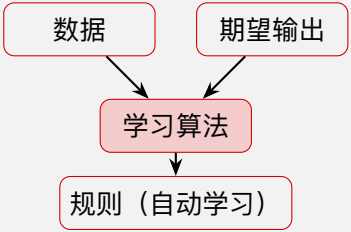

核心区别

传统方法需要人工设计规则和特征；机器学习从数据中**自动学习**规则和特征。

以图像分类为例

传统机器学习流程

1. 人工设计特征（SIFT、HOG 等）
2. 特征提取
3. 训练分类器（SVM 等）
4. 预测

瓶颈：特征工程依赖专家经验

深度学习流程

1. 输入原始图像
2. 神经网络**自动**学习特征
3. 端到端训练
4. 预测

优势：自动特征提取，端到端优化

深度学习的核心优势：用表示学习取代手工特征工程

表示学习

自动发现用于检测或分类的数据表示方法，无需人工设计特征。

端到端学习

直接从原始输入到最终输出的学习范式，中间特征全部由网络自动学习。

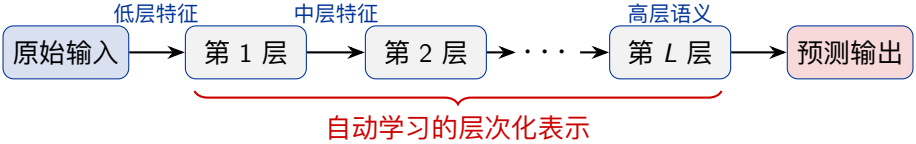

传统方法：手工特征

- 是否包含 “免费”“中奖” 等关键词
- 发件人是否在黑名单中
- 邮件中链接数量
- 是否全部大写
- 发送时间是否异常

→ 需要领域专家逐一设计

深度学习方法：自动学习

- 输入：邮件原始文本
- 词嵌入层：学习词的表示
- 隐藏层：自动提取特征
- 输出层：垃圾/正常分类

→ 特征由数据驱动自动学习

思考

如果让你设计一个垃圾邮件过滤器，你会提取哪些特征？深度学习能发现你想不到的特征吗？

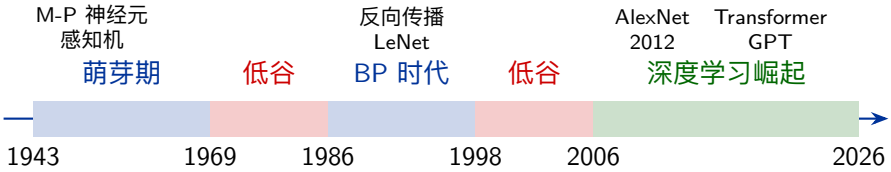

“两起两落”的历史

深度学习经历了两次兴衰，最终在大数据、大算力的推动下迎来全面爆发。

关键里程碑

- **1943**：McCulloch & Pitts 提出 M-P 神经元模型——首次用数学模型描述神经元
- **1958**：Rosenblatt 提出**感知机**（Perceptron）——第一个可学习的神经网络模型
- **1969**：Minsky & Papert 出版《Perceptrons》——证明感知机无法解决 XOR 问题

XOR 问题

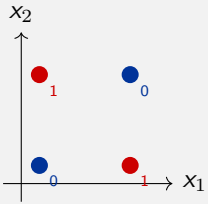

线性不可分！

影响

Minsky 的批判导致神经网络研究经费大幅削减，进入第一次 “AI 寒冬”。

复兴的关键突破

- **1982**：Hopfield 网络——将物理学思想引入神经网络
- **1986**：Rumelhart、Hinton、Williams 提出**反向传播算法**（BP）——解决了多层网络的训练问题
- **1989**：LeCun 提出 **LeNet**——用于手写数字识别，卷积神经网络的开端
- **1997**：Hochreiter & Schmidhuber 提出 **LSTM**——解决长程依赖问题

反向传播的意义

BP 算法利用**链式法则**高效计算多层网络中每个参数的梯度，使得深层网络的训练成为可能。这是深度学习最核心的算法之一。

SVM 崛起

- **1995**：Vapnik 提出支持向量机
- 坚实的数学理论基础
- 凸优化，有全局最优解
- 在小数据上表现优异
- 核方法扩展到非线性

神经网络的困境

- 训练不稳定（梯度消失）
- 缺乏理论保证
- 计算资源不足
- 数据集规模有限
- 研究经费和关注度下降

思考

为什么神经网络在 1990 年代再次 “失宠”？是什么让它最终翻身？

里程碑事件

- 2006 Hinton 提出**深度信念网络**（DBN）——逐层预训练策略，突破深层网络训练瓶颈
- 2009 ImageNet 大规模图像数据集发布——1400 万张图像，2 万多类别
- 2012 **AlexNet** 赢得 ImageNet 竞赛——错误率从 26% 降至 16%，深度学习爆发的标志
- 2014 GAN（生成对抗网络）被提出——开创生成模型新范式
- 2015 **ResNet** 提出残差连接——使训练超过 100 层的网络成为可能
- 2016 AlphaGo 击败世界围棋冠军——深度强化学习的里程碑

Transformer 与大语言模型

2017 Google 提出 **Transformer**——“Attention Is All You Need”

2018 **BERT**——预训练 + 微调范式，NLP 革命

2020 **GPT-3**——1750 亿参数，涌现能力

2022 **ChatGPT** 发布——AI 进入公众视野

2023– GPT-4、多模态大模型、AI Agent

模型规模增长

- AlexNet: 6000 万参数
- BERT: 3.4 亿参数
- GPT-3: 1750 亿参数
- 规模每年增长约 10 倍

发展趋势

- 模型越来越大
- 多模态融合
- 通用人工智能探索
- 高效推理与部署

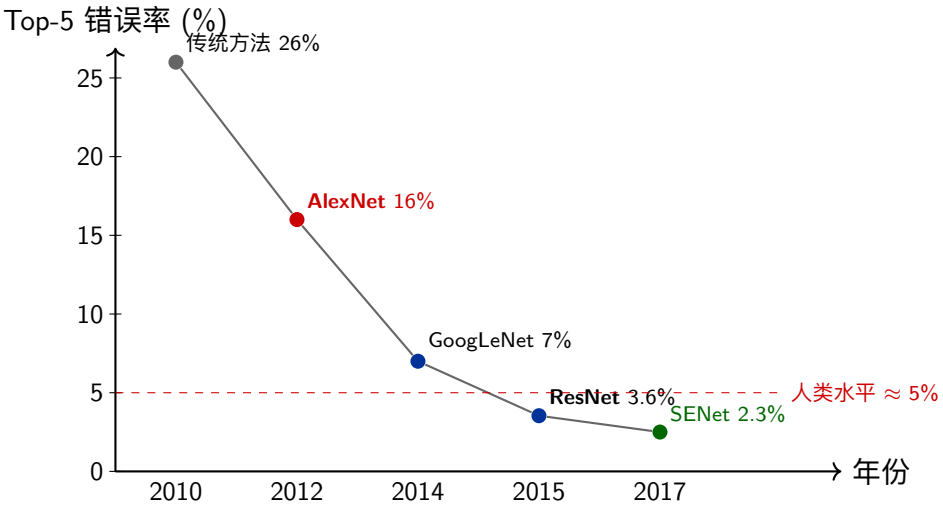

2015 年起，深度学习模型在 ImageNet 上**超越人类水平**

“两起两落” 的原因

- **第一次低谷**（1969）：感知机能力有限 + 缺乏训练算法
- **第二次低谷**（1990s）：梯度消失 + 数据不足 + 算力有限

最终崛起的原因

- **数据**：互联网带来海量数据
- **算力**：GPU 并行计算突破
- **算法**：ReLU、Dropout、BN 等关键技术
- **生态**：开源框架降低门槛

历史规律

技术的发展不是线性的，而是螺旋上升的。基础理论的积累 + 工程条件的成熟 = 技术爆发。

图像分类与检测

- **图像分类**：识别图像中的物体类别
- **目标检测**：定位并识别多个物体
- **语义分割**：像素级分类
- **人脸识别**：身份验证

图像生成

- **风格迁移**：将照片转为名画风格
- **图像超分辨率**：增强图像清晰度
- **DALL-E / Stable Diffusion**：文本生成图像
- **图像修复**：填补缺失区域

核心模型

CNN（卷积神经网络）是计算机视觉领域的基石，后续课程将重点讲解。

NLP 的核心任务

- **机器翻译**：Google Translate
- **文本生成**：ChatGPT、文心一言
- **情感分析**：评论正/负面判断
- **命名实体识别**：提取人名、地点等
- **文本摘要**：自动生成摘要
- **问答系统**：智能客服
- **对话系统**：聊天机器人
- **代码生成**：Copilot

发展脉络

RNN/LSTM $\longrightarrow$ Attention 机制 $\longrightarrow$ **Transformer** $\longrightarrow$ BERT/GPT $\longrightarrow$ 大语言模型

语音识别（ASR）

- 将语音信号转换为文字
- 应用：Siri、小爱同学
- 实时字幕生成
- 会议记录与转写

语音合成（TTS）

- 将文字转换为自然语音
- 应用：导航语音播报
- 有声书自动生成
- 语音克隆技术

技术发展

- 传统方法：HMM + GMM
- 深度学习：端到端语音识别（DeepSpeech、Whisper）
- 最新进展：多模态语音理解（语音 + 视觉 + 语言）

AlphaFold：蛋白质结构预测

- 蛋白质折叠问题：50 年未解之谜
- AlphaFold2（2020）：精度达到实验水平
- 预测了 2 亿多种蛋白质结构
- 荣获 2024 年诺贝尔化学奖

其他科学应用

- **药物发现**：加速候选药物筛选
- **气象预测**：GraphCast 天气预报
- **材料科学**：新材料性质预测
- **物理模拟**：流体力学、粒子物理

AI for Science

深度学习正在成为科学研究的“第四范式”，与实验、理论、计算并列的科学发现工具。

推荐系统

- 电商商品推荐
- 短视频推荐
- 新闻个性化
- 音乐/电影推荐

自动驾驶

- 环境感知
- 路径规划
- 行为决策
- 端到端驾驶

游戏 AI

- AlphaGo（围棋）
- AlphaStar（星际争霸）
- OpenAI Five（Dota 2）
- 游戏内容生成

深度学习正在渗透到人类活动的方方面面

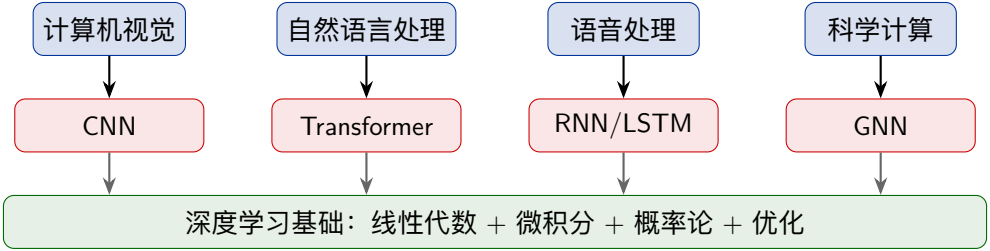

课程定位

本课程聚焦**底层基础**，掌握核心模型（CNN、RNN、Transformer）的原理与实现。

核心思想

深度神经网络通过逐层变换，将原始数据映射为越来越抽象、越来越有用的表示。

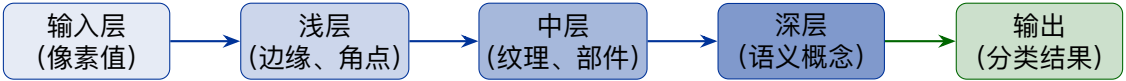

关键优势

组合爆炸：n 个特征可组合出指数级的表示，深度网络通过层次化组合高效利用这一点。

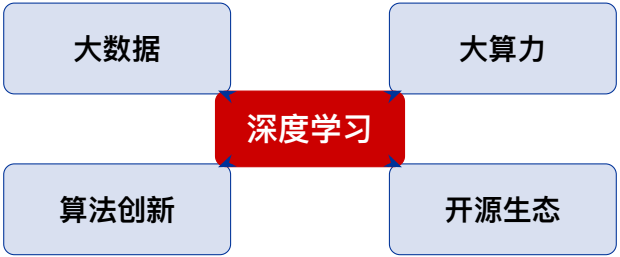

数据 + 算力

- 互联网数据爆炸
- ImageNet 等大规模数据集
- GPU 并行计算能力
- 云计算平台普及

算法 + 生态

- ReLU、Dropout、BN 等技术
- 残差连接、注意力机制
- PyTorch、TensorFlow
- 预训练模型共享（HuggingFace）

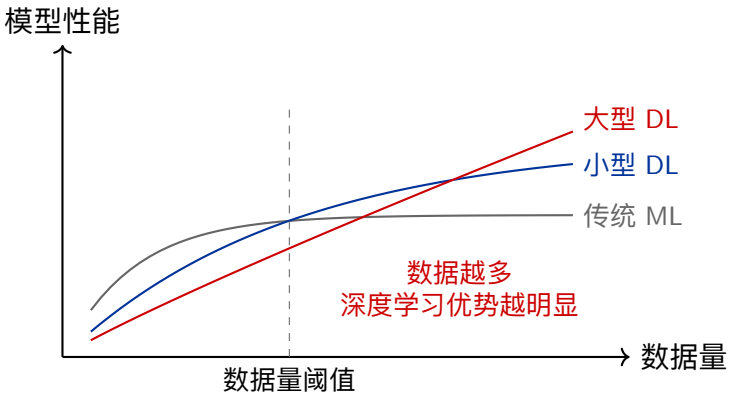

观察

在小数据量下，传统方法可能更优；当数据量充分时，深度学习的性能**持续提升**，且模型越大提升越显著。

主流框架

框架	特点
PyTorch	动态图，研究首选
TensorFlow	静态图，工业部署
JAX	函数式，高性能
PaddlePaddle	百度开源

开源资源

- **HuggingFace**：预训练模型仓库
- **GitHub**：代码开源共享
- **arXiv**：论文预印本
- **Kaggle**：竞赛与数据集
- **Colab**：免费 GPU 环境

本课程使用 PyTorch

PyTorch 以其 Pythonic 的 API 和动态计算图，成为学术研究最流行的深度学习框架。

数据依赖

- 大量**标注数据**是性能的基础
- 标注成本高昂（医学图像、自动驾驶）
- 数据偏见导致模型偏见
- 数据隐私与合规问题

应对策略

- 数据增强（Data Augmentation）
- 迁移学习（Transfer Learning）
- 自监督学习（Self-supervised）
- 少样本学习（Few-shot）
- 联邦学习（Federated Learning）

“黑箱”问题

- 深度网络难以解释决策依据
- 在医疗、法律等领域受限
- 可解释 AI（XAI）是活跃研究方向
- 方法：注意力可视化、LIME、SHAP

对抗鲁棒性

- **对抗样本**：微小扰动导致分类错误
- 人眼不可察觉的修改可欺骗模型
- 安全关键应用的重大隐患
- 对抗训练是主要防御手段

思考

“熊猫”图像加入微小噪声后被识别为“长臂猿”——这说明深度学习还缺乏什么能力？

计算资源消耗

- GPT-3 训练成本约 1200 万美元
- 大模型训练的碳排放问题
- GPU 资源成为研究瓶颈
- 模型压缩与高效推理是关键

推理与泛化

- 缺乏**因果推理**能力
- 难以进行**逻辑推理**
- 分布外泛化能力不足
- “幻觉”问题（生成看似合理但错误的内容）

公平性与伦理

- 训练数据中的偏见会被模型放大
- AI 决策系统需要公平性保障
- 深度伪造（Deepfake）技术的滥用风险

局限性	表现	研究方向
数据依赖	需要大量标注数据	自监督学习、少样本学习
可解释性	“黑箱”决策过程	XAI、注意力分析
计算成本	训练资源消耗巨大	模型压缩、知识蒸馏
鲁棒性	对抗样本脆弱	对抗训练、认证防御
推理能力	缺乏逻辑和因果推理	神经符号融合
公平性	数据偏见导致歧视	公平性约束、去偏技术

辩证看待

深度学习正在快速发展中，这些局限性正是当前研究的热点方向。

核心要点

1. **AI ⊃ ML ⊃ DL**：深度学习是机器学习的子集，机器学习是人工智能的子集
2. **核心区别**：深度学习用表示学习取代手工特征工程，实现端到端学习
3. **发展历史**：经历“两起两落”，最终在数据、算力、算法、生态四大因素推动下全面爆发
4. **广泛应用**：计算机视觉、NLP、语音、科学计算等领域取得巨大成功
5. **局限与挑战**：数据依赖、可解释性、计算成本、鲁棒性、推理能力等问题仍待解决

第 2 讲：数学基础

- 线性代数：向量、矩阵、张量、范数、特征值
- 微积分：导数、链式法则、偏导数、梯度
- 概率论：贝叶斯定理、高斯分布
- 梯度下降法入门

课后任务

1. 浏览 PyTorch 官网（`pytorch.org`），安装 PyTorch 环境
2. 运行一个简单的 Tensor 操作示例：创建两个随机张量，计算矩阵乘法，打印结果与形状
3. 思考：AI、ML、DL 三者的关系，各举一个不在课堂上提到的应用实例

谢谢！

问题与讨论

孟翰
人工智能学院
中国石油大学（北京）

hmeng@cup.edu.cn