深度学习基础

第 2 讲 — 数学基础

孟翰

人工智能学院
中国石油大学（北京）

2026 年春季学期

本讲内容

1. 线性代数基础
2. 微积分基础
3. 概率论基础
4. 梯度下降法入门
5. 本讲小结与下讲预告

数学是深度学习的语言

- **线性代数**：描述数据与模型运算（矩阵乘法 = 前向传播）
- **微积分**：理解模型如何学习（链式法则 = 反向传播）
- **概率论**：处理不确定性（损失函数、生成模型）
- **优化理论**：训练模型的核心引擎（梯度下降）

本讲目标

不是从零学习数学，而是从**深度学习视角**重新梳理关键数学工具，明确每个概念在后续课程中的用途。

基本定义

- **标量**（Scalar）：单个数值

$$x \in \mathbb{R}$$

- **向量**（Vector）：一列有序数

$$\boldsymbol{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n$$

矩阵与张量

- **矩阵**（Matrix）：二维数组

$$\boldsymbol{A} = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \in \mathbb{R}^{m \times n}$$

- **张量**（Tensor）：多维数组的推广

$$\mathcal{T} \in \mathbb{R}^{d_1 \times d_2 \times \cdots \times d_k}$$

深度学习中的表示约定

类型	记号	示例
标量	小写斜体 x	学习率 η，损失值 L
向量	粗体小写 $\boldsymbol{x}$	输入特征 $\boldsymbol{x}$，权重 $\boldsymbol{w}$
矩阵	粗体大写 $\boldsymbol{W}$	权重矩阵 $\boldsymbol{W}$，Jacobian $\boldsymbol{J}$
张量	花体大写 $\mathcal{T}$	图像批次 $\mathcal{X}$

RGB 图像是一个三阶张量

- 一张 RGB 图像：$\mathcal{I} \in \mathbb{R}^{H \times W \times 3}$（高度 × 宽度 × 通道数）
- 一个批次的图像：$\mathcal{X} \in \mathbb{R}^{N \times H \times W \times 3}$（批量大小 × 高度 × 宽度 × 通道）
- 张量在深度学习中**无处不在**——PyTorch 的核心数据结构就是 `torch.Tensor`

加法与标量乘法

矩阵加法（逐元素）：

$$(\boldsymbol{A}+\boldsymbol{B})_{ij} = A_{ij} + B_{ij}$$

标量乘法：

$$(c\boldsymbol{A})_{ij} = c \cdot A_{ij}$$

转置：

$$(\boldsymbol{A}^\top)_{ij} = A_{ji}$$

Hadamard 积

逐元素乘法（区别于矩阵乘法）：

$$(\boldsymbol{A} \odot \boldsymbol{B})_{ij} = A_{ij} \cdot B_{ij}$$

注意区分：

- $\boldsymbol{AB}$：矩阵乘法（线性变换）
- $\boldsymbol{A} \odot \boldsymbol{B}$：逐元素乘法

定义

设 $\boldsymbol{A} \in \mathbb{R}^{m\times k}$，$\boldsymbol{B} \in \mathbb{R}^{k\times n}$，则 $\boldsymbol{C} = \boldsymbol{AB} \in \mathbb{R}^{m\times n}$：

$$\boxed{C_{ij} = \sum_{l=1}^{k} A_{il} B_{lj}}$$

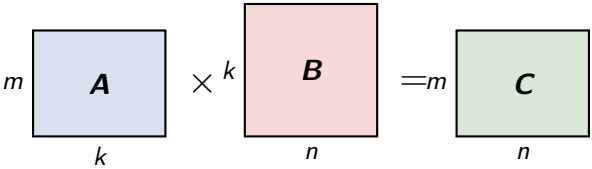

维度匹配条件

$\boldsymbol{A}$ 的**列数**必须等于 $\boldsymbol{B}$ 的**行数**。结果矩阵的维度为 $\boldsymbol{A}$ 的行数 $\times$ $\boldsymbol{B}$ 的列数。

课堂练习

计算 $\boldsymbol{AB}$:

$$\boldsymbol{A} = \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix}, \quad \boldsymbol{B} = \begin{pmatrix} 7 & 10 \\ 8 & 11 \\ 9 & 12 \end{pmatrix}$$

解答

$\boldsymbol{A} \in \mathbb{R}^{2\times 3}$, $\boldsymbol{B} \in \mathbb{R}^{3\times 2}$, $\boldsymbol{C} = \boldsymbol{AB} \in \mathbb{R}^{2\times 2}$:

$$\boldsymbol{C} = \begin{pmatrix} 1\cdot 7 + 2\cdot 8 + 3\cdot 9 & 1\cdot 10 + 2\cdot 11 + 3\cdot 12 \\ 4\cdot 7 + 5\cdot 8 + 6\cdot 9 & 4\cdot 10 + 5\cdot 11 + 6\cdot 12 \end{pmatrix} = \begin{pmatrix} 50 & 68 \\ 122 & 167 \end{pmatrix}$$

在深度学习中

矩阵乘法是神经网络**前向传播**的核心运算：$\boldsymbol{h} = \boldsymbol{Wx} + \boldsymbol{b}$

内积（点积）

$$\boldsymbol{x} \cdot \boldsymbol{y} = \boldsymbol{x}^\top \boldsymbol{y} = \sum_{i=1}^{n} x_i y_i$$

几何含义：$\boldsymbol{x} \cdot \boldsymbol{y} = \|\boldsymbol{x}\| \|\boldsymbol{y}\| \cos\theta$（衡量两个向量的相似度）

常用向量范数

L1 范数（曼哈顿距离）：

$$\|\boldsymbol{x}\|_1 = \sum_{i=1}^{n} |x_i|$$

→ L1 正则化（稀疏性）

L2 范数（欧氏距离）：

$$\|\boldsymbol{x}\|_2 = \sqrt{\sum_{i=1}^{n} x_i^2}$$

→ L2 正则化（权重衰减）

∞ 范数：

$$\|\boldsymbol{x}\|_\infty = \max_i |x_i|$$

→ 最大绝对值

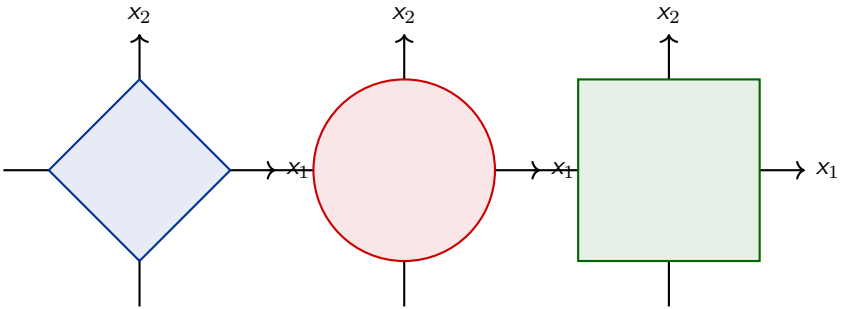

L1 范数（菱形） $|x_1| + |x_2| = 1$

L2 范数（圆形） $x_1^2 + x_2^2 = 1$

∞ 范数（方形） $\max(|x_1|, |x_2|) = 1$

思考

L1 范数的“菱形”等值线在坐标轴上有“尖角”——这对正则化会产生什么影响？（提示：参数更容易被“推”到零）

定义

对于方阵 $\boldsymbol{A} \in \mathbb{R}^{n\times n}$，若存在非零向量 $\boldsymbol{v}$ 和标量 λ 使得：

$$\boxed{\boldsymbol{A}\boldsymbol{v} = \lambda \boldsymbol{v}}$$

则 λ 为**特征值**，$\boldsymbol{v}$ 为对应的**特征向量**。

几何含义

矩阵 $\boldsymbol{A}$ 作为线性变换，特征向量是变换后**方向不变**的向量，特征值是**缩放因子**。

计算示例

$$\boldsymbol{A} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

特征值：$\lambda_1 = 3$，$\lambda_2 = 1$

特征向量：$\boldsymbol{v}_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$，$\boldsymbol{v}_2 = \begin{pmatrix} 1 \\ -1 \end{pmatrix}$

主要应用场景

- **PCA 降维**：对数据协方差矩阵做特征分解，选取最大特征值对应的特征向量作为主成分
- **Hessian 矩阵分析**：特征值反映损失函数曲面的曲率，帮助理解优化难度
- **训练动态**：分析权重矩阵的特征值分布，诊断梯度爆炸/消失问题

直觉记忆

特征值 = 变换的 “强度”，特征向量 = 变换的 “方向”。理解一个矩阵的特征分解，就是理解它作为线性变换的本质。

概念	公式	在深度学习中的用途
矩阵乘法	$C_{ij} = \sum_l A_{il} B_{lj}$	前向传播的核心运算
转置	$(\boldsymbol{A}^\top)_{ij} = A_{ji}$	梯度计算
L2 范数	$\|\boldsymbol{x}\|_2 = \sqrt{\sum x_i^2}$	权重衰减/L2 正则化
L1 范数	$\|\boldsymbol{x}\|_1 = \sum \|x_i\|$	稀疏正则化
特征值	$\boldsymbol{A}\boldsymbol{v} = \lambda \boldsymbol{v}$	PCA、Hessian 分析

关键记忆

- 矩阵乘法的维度匹配：$(m \times k) \times (k \times n) = (m \times n)$
- L1 范数促进稀疏，L2 范数促进平滑
- 特征向量是线性变换的 “不变方向”

导数的定义

函数 $f(x)$ 在 x 处的导数：

$$f'(x) = \lim_{\Delta x \to 0} \frac{f(x+\Delta x) - f(x)}{\Delta x}$$

几何含义：函数曲线在该点切线的斜率

常用导数公式

函数	导数	函数	导数
x^n	nx^{n-1}	$\ln x$	$1/x$
e^x	e^x	$\sin x$	$\cos x$
a^x	$a^x \ln a$	$\cos x$	$-\sin x$

激活函数的导数（预告）

Sigmoid 函数：

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

$$\sigma'(x) = \sigma(x)(1-\sigma(x))$$

ReLU 函数：

$$\mathrm{ReLU}(x) = \max(0, x)$$

$$\mathrm{ReLU}'(x) = \begin{cases} 1, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

为什么导数如此重要?

训练神经网络 = 通过求导来计算**梯度** → 用梯度指导**参数更新**。导数的计算效率直接影响训练速度。

单变量链式法则

若 $y = f(u)$，$u = g(x)$，则：

$$\boxed{\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx} = f'(g(x)) \cdot g'(x)}$$

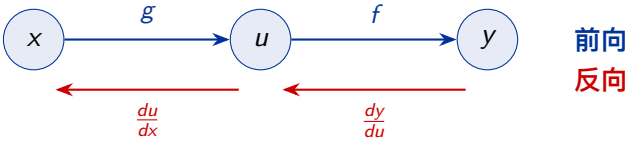

直觉理解

链式法则 = 每一层的“放大率”连乘：$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx}$。这正是**反向传播算法**的数学基础！

例 1：计算 $y = (x^2+1)^3$ 的导数

令 $u = x^2+1$，则 $y = u^3$

$$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx} = 3u^2 \cdot 2x = 6x(x^2+1)^2$$

例 2：多层复合

若 $y = f_3(f_2(f_1(x)))$，令 $u_1 = f_1(x)$，$u_2 = f_2(u_1)$，$y = f_3(u_2)$：

$$\frac{dy}{dx} = \frac{dy}{du_2} \cdot \frac{du_2}{du_1} \cdot \frac{du_1}{dx} = f_3'(u_2) \cdot f_2'(u_1) \cdot f_1'(x)$$

与深度学习的联系

一个 L 层的神经网络 $= L$ 个函数的复合。反向传播就是从输出层到输入层逐层应用链式法则。

课堂练习

计算 $f(x) = (3x^2 + 1)^4$ 的导数

解答

令 $u = 3x^2 + 1$，则 $f = u^4$

$$\begin{aligned}\frac{df}{dx} &= \frac{df}{du} \cdot \frac{du}{dx} \\ &= 4u^3 \cdot 6x \\ &= 24x(3x^2 + 1)^3\end{aligned}$$

练习 2（课后思考）

设 $f(x) = \sigma(wx + b)$，其中 $\sigma(z) = \frac{1}{1+e^{-z}}$。利用链式法则求 $\frac{\partial f}{\partial w}$。

提示

1. 令 $z = wx + b$，则 $f = \sigma(z)$
2. 利用 $\sigma'(z) = \sigma(z)(1 - \sigma(z))$
3. 应用链式法则：$\frac{\partial f}{\partial w} = \frac{d\sigma}{dz} \cdot \frac{\partial z}{\partial w}$

定义

对于多元函数 $f(x_1, x_2, \ldots, x_n)$，固定其他变量，对 x_i 求导：

$$\frac{\partial f}{\partial x_i} = \lim_{\Delta x_i \to 0} \frac{f(\ldots, x_i + \Delta x_i, \ldots) - f(\ldots, x_i, \ldots)}{\Delta x_i}$$

示例

$f(x, y) = x^2 y + \sin(xy)$

$$\frac{\partial f}{\partial x} = 2xy + y\cos(xy)$$

$$\frac{\partial f}{\partial y} = x^2 + x\cos(xy)$$

核心观点

损失函数 $L(\boldsymbol{\theta})$ 依赖成千上万个参数，我们需要对**每个参数**求偏导数。

直觉理解

- $\frac{\partial L}{\partial \theta_i}$ 告诉我们：当只微调参数 θ_i 时，损失函数如何变化
- 每个偏导数 = 一个参数的 "调整方向"
- 所有偏导数汇总 $\rightarrow$ 梯度向量（下一节内容）

梯度的定义

函数 $f: \mathbb{R}^n \to \mathbb{R}$ 的梯度是所有偏导数组成的向量：

$$\nabla f = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \ldots, \frac{\partial f}{\partial x_n} \right)^\top \in \mathbb{R}^n$$

核心性质

- 指向函数值**增长最快**的方向
- **负梯度**方向是下降最快的方向
- 与等高线**正交**

直觉类比——站在山上

- 梯度 = 最陡上坡方向
- 负梯度 = 最陡下坡方向
- 梯度下降 = 沿最陡方向下山

示例

$f(x, y) = x^2 + 2y^2$

$$\nabla f = \begin{pmatrix} 2x \\ 4y \end{pmatrix}$$

在点 $(1, 1)$ 处：$\nabla f = (2, 4)^\top$

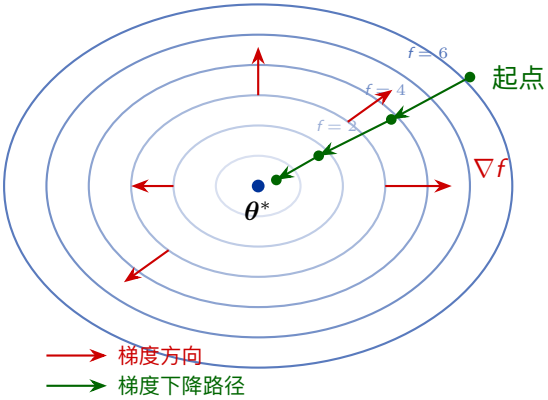

关键观察

- 梯度 ∇f 始终**垂直于**等高线
- 梯度**大小**反映变化剧烈程度
- 极值点处 $\nabla f = \mathbf{0}$

梯度下降

沿**负梯度**方向（绿色路径）逐步逼近最小值 $\boldsymbol{\theta}^*$。

名称由来

以德国数学家 **Carl Gustav Jacob Jacobi**（1804–1851）命名。Jacobi 是 19 世纪最重要的数学家之一，在椭圆函数、行列式理论和力学等领域做出了奠基性贡献。

定义

对于向量值函数 $\boldsymbol{f}: \mathbb{R}^n \to \mathbb{R}^m$，Jacobian 矩阵 $\boldsymbol{J} \in \mathbb{R}^{m \times n}$：

$$\boldsymbol{J} = \begin{pmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \frac{\partial f_m}{\partial x_2} & \cdots & \frac{\partial f_m}{\partial x_n} \end{pmatrix}$$

每一行是一个输出分量对所有输入的偏导数（即一个梯度的转置）。

核心联系

反向传播的推导本质上是 **Jacobian 矩阵的连乘**。

梯度消失问题

若 Jacobian 矩阵的元素持续小于 1，连乘后趋近零——这就是**梯度消失**问题的根源。

$$\frac{\partial L}{\partial \boldsymbol{x}^{(1)}} = \boldsymbol{J}^{(L)} \cdot \boldsymbol{J}^{(L-1)} \cdots \boldsymbol{J}^{(2)} \cdot \frac{\partial L}{\partial \boldsymbol{x}^{(L)}}$$

层数 L 越多，连乘的 Jacobian 矩阵越多，梯度越容易消失或爆炸。

名称由来

以德国数学家 **Ludwig Otto Hesse**（1811–1874）命名。Hesse 在代数几何和不变量理论方面做出了重要贡献，他系统研究了二阶偏导数构成的矩阵，后人以他的名字命名为 Hessian 矩阵。

定义

对于标量函数 $f: \mathbb{R}^n \to \mathbb{R}$，Hessian 矩阵 $\boldsymbol{H} \in \mathbb{R}^{n \times n}$：

$$H_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$$

Hessian 矩阵是**对称矩阵**，包含函数的二阶偏导数信息。

几何含义

- Hessian 描述损失函数曲面的**曲率**
- 特征值 > 0：局部凸（碗形）
- 特征值 < 0：局部凹
- 混合正负：鞍点

在深度学习中

- 分析损失函数的局部结构
- 指导学习率选择
- 二阶优化方法（Newton 法）
- 实际中因维度太高很少直接计算

概念	公式	在深度学习中的用途
链式法则	$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx}$	反向传播算法的数学基础
梯度	$\nabla f = \left(\frac{\partial f}{\partial x_1}, \ldots, \frac{\partial f}{\partial x_n}\right)^\top$	参数优化方向
Jacobian	$J_{ij} = \frac{\partial f_i}{\partial x_j}$	反向传播中的矩阵链乘
Hessian	$H_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$	分析损失函数曲面曲率

最核心的一句话

链式法则是连接“数学”与“深度学习”的桥梁——它使得多层网络的训练成为可能。

随机变量与概率分布

- **随机变量** X：取值不确定的变量
- **离散分布**：$P(X = x_i)$，概率质量函数（PMF）
- **连续分布**：$p(x)$，概率密度函数（PDF），$P(a \leq X \leq b) = \int_a^b p(x)\,dx$
- **概率公理**：$P(A) \geq 0$，$P(\Omega) = 1$，互斥事件可加

条件概率

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

“在 B 发生的条件下，A 发生的概率”

贝叶斯定理

$$\boxed{P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}}$$

- $P(A)$：**先验概率**——观察数据前对 A 的信念
- $P(A|B)$：**后验概率**——观察到 B 后对 A 的更新信念
- $P(B|A)$：**似然**——A 为真时观察到 B 的概率
- $P(B)$：**证据**——归一化常数

核心思想

贝叶斯定理描述了如何根据**新的证据**来**更新信念**：先验 $\xrightarrow{\text{数据}}$ 后验

医学检测问题

某疾病患病率为 1%。检测灵敏度为 99%（有病查出阳性的概率），特异度为 95%（没病查出阴性的概率）。一个人检测为阳性，他真正患病的概率是多少?

解答

$$P(\text{患病}|\text{阳性}) = \frac{P(\text{阳性}|\text{患病}) \cdot P(\text{患病})}{P(\text{阳性})} = \frac{0.99 \times 0.01}{0.99 \times 0.01 + 0.05 \times 0.99} \approx \mathbf{16.7\%}$$

反直觉的结果

即使检测准确率很高，由于患病率（先验）很低，阳性结果中真正患病的比例也不高！这说明**先验概率**对后验结果的影响巨大。

期望（均值）

离散随机变量：

$$\mathbb{E}[X] = \sum_x x \cdot P(X = x)$$

连续随机变量：

$$\mathbb{E}[X] = \int_{-\infty}^{\infty} x \cdot p(x)\, dx$$

方差

衡量随机变量偏离均值的程度：

$$\mathrm{Var}(X) = \mathbb{E}\left[(X - \mathbb{E}[X])^2\right] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$$

标准差：$\sigma = \sqrt{\mathrm{Var}(X)}$

期望的应用

- **期望风险**：损失函数的期望 $\mathbb{E}_{(\boldsymbol{x},y)\sim p_{\text{data}}}[L(f(\boldsymbol{x}),y)]$ 是我们真正想要最小化的目标
- **经验风险**：用训练数据的均值近似期望

方差的应用

- **偏差-方差分解**：模型误差 $=$ 偏差 ^{2} $+$ 方差 $+$ 噪声
- 偏差高 $\rightarrow$ 欠拟合，方差高 $\rightarrow$ 过拟合
- 理解这一分解有助于选择模型复杂度

伯努利分布

$X \in \{0, 1\}$，参数 p：

$$P(X = 1) = p, \quad P(X = 0) = 1 - p$$

$$\mathbb{E}[X] = p, \quad \mathrm{Var}(X) = p(1 - p)$$

应用：二分类问题的标签建模

高斯（正态）分布

$$\boxed{p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)}$$

$$\mathbb{E}[X] = \mu, \quad \mathrm{Var}(X) = \sigma^2$$

应用：权重初始化、噪声建模、VAE

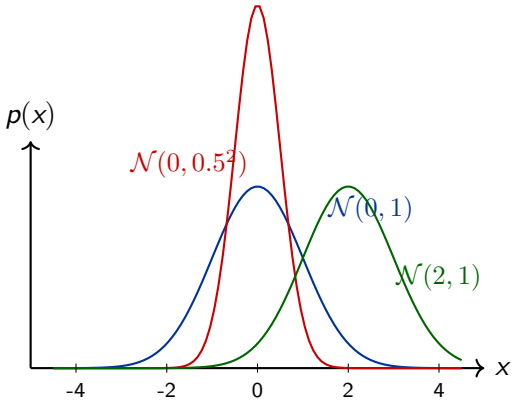

在深度学习中的地位

- **权重初始化**：$w \sim \mathcal{N}(0, \sigma^2)$ (Xavier/He 初始化)
- **噪声建模**：随机误差常假设为高斯噪声
- **变分推断**：VAE 中隐变量的先验分布

概念	公式	用途
贝叶斯定理	$P(A\|B) = \frac{P(B\|A)P(A)}{P(B)}$	概率推断、贝叶斯学习
期望	$\mathbb{E}[X] = \sum xP(x)$	损失函数的期望风险
方差	$\mathrm{Var}(X) = \mathbb{E}[(X-\mu)^2]$	偏差-方差分解
高斯分布	$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	权重初始化、概率建模

核心记忆

- 贝叶斯定理：根据新证据更新信念（先验 $\rightarrow$ 后验）
- 高斯分布：深度学习中最常用的概率分布
- 期望和方差：理解模型性能和稳定性的基本工具

深度学习的核心优化问题

寻找最优参数 $\boldsymbol{\theta}^*$ 使得损失函数最小：

$$\boldsymbol{\theta}^* = \arg\min_{\boldsymbol{\theta}} L(\boldsymbol{\theta})$$

梯度下降更新规则

$$\boxed{\boldsymbol{\theta}^{(t+1)} = \boldsymbol{\theta}^{(t)} - \eta \nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}^{(t)})}$$

- $\boldsymbol{\theta}^{(t)}$：第 t 步的参数值
- η：**学习率**（步长）
- $\nabla_{\boldsymbol{\theta}} L$：损失函数对参数的梯度
- 沿负梯度方向更新 = 沿**下降最快**的方向前进

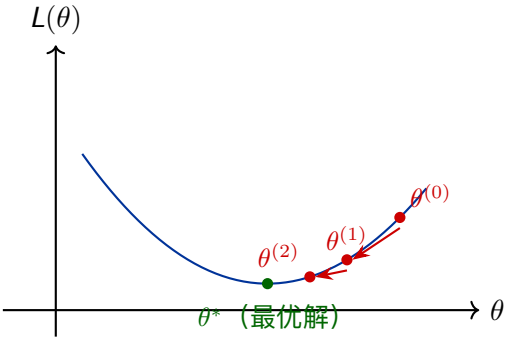

直觉

- 梯度 > 0（上坡）$\Rightarrow$ 向左移（减小 θ）
- 梯度 < 0（下坡）$\Rightarrow$ 向右移（增大 θ）
- 接近最小值时，梯度趋近零，步长自然变小

学习率太小

收敛太慢

学习率适当

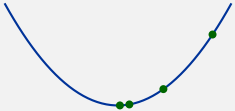

快速收敛

学习率太大

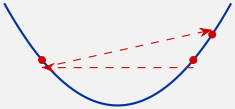

震荡/发散

实践建议

- 常用初始学习率：0.01 或 0.001
- 学习率衰减策略：随训练进行逐渐减小学习率
- 自适应学习率：Adam 等优化器（后续课程详述）

课堂练习

最小化 $f(x) = x^2$，初始点 $x_0 = 4$，学习率 $\eta = 0.3$，计算前 4 步。

解答

导数 $\dfrac{df}{dx} = 2x$，更新：$x^{(t+1)} = x^{(t)} - \eta \cdot 2x^{(t)} = 0.4\,x^{(t)}$

步骤 t	$x^{(t)}$	导数值	$f(x^{(t)})$
0	4.000	8.000	16.000
1	1.600	3.200	2.560
2	0.640	1.280	0.410
3	0.256	0.512	0.066
4	0.102	0.205	0.010

观察：每步 x 缩小为原来的 0.4 倍，快速向最优解 $x^* = 0$ 收敛。

思考

为什么不直接令梯度等于零 $\nabla L = \mathbf{0}$ 来求解析解?

原因

1. **非凸问题**：深度网络的损失函数通常是非凸的，无法直接求解
2. **高维参数**：现代网络有百万到千亿参数，解析求解不可行
3. **无解析解**：大多数损失函数没有闭式解（线性回归是少数例外）
4. **数据量大**：需要在大规模数据上高效计算

高维推广

梯度下降在高维空间中同样适用：每个参数沿各自的偏导数方向独立更新。

核心知识点回顾

模块	核心公式	深度学习用途
线性代数	$C_{ij} = \sum A_{il}B_{lj}$, $\|\mathbf{x}\|_2$	前向传播、正则化
微积分	$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx}$, ∇f	反向传播、梯度计算
概率论	$P(A\|B) = \frac{P(B\|A)P(A)}{P(B)}$	贝叶斯推断、概率建模
优化	$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta\nabla L$	模型训练

三个最重要的公式

1. **链式法则**：$\frac{dy}{dx} = \frac{dy}{du} \cdot \frac{du}{dx}$（反向传播的基础）
2. **梯度下降**：$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta\nabla L$（训练的核心算法）
3. **高斯分布**：$p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$（权重初始化、概率建模）

第 3 讲：机器学习基础

- 监督学习、无监督学习、强化学习
- 数据集划分与交叉验证
- 线性回归模型与梯度下降训练
- 模型评估指标（准确率、F1 等）
- 过拟合与欠拟合

课后作业

1. 证明：$\|\boldsymbol{x}\|_\infty \le \|\boldsymbol{x}\|_2 \le \|\boldsymbol{x}\|_1$
2. 设 $f(x) = \sigma(wx + b)$，利用链式法则求 $\frac{\partial f}{\partial w}$ 和 $\frac{\partial f}{\partial b}$
3. 用梯度下降法求解 $\min_x (x-3)^2 + 2$，$x_0 = 0$，$\eta = 0.4$，计算前 5 步
4. 思考：若 Jacobian 矩阵的元素都小于 1，连乘 L 层后会发生什么？

孟翰
人工智能学院
中国石油大学（北京）

hmeng@cup.edu.cn